หลักสูตรการอบรม

Introduction to Data Analytics and Data Science

โครงการจ้างพัฒนาระบบปัญญาประดิษฐ์ (AI) สนับสนุนการยกระดับกลไกการขับเคลื่อนการบริหารด้วยข้อมูล (Data Driven) เพื่อเพิ่มโอกาส เติมทุน และเพิ่มสภาพคล่องอุตสาหกรรมไทย (กองทุนพัฒนาดิจิทัลเพื่อเศรษฐกิจและสังคม)

สัญญาเลขที่ ลงวันที่ 29 กันยายน 2568

วันพุธที่ 24 มิถุนายน 2569

ห้องประชุม ชั้น 3 อาคารสำนักงานอ้อยและน้ำตาลทราย

OCSB/Primes solution and services. All rights reserved.

1. Introduction to Data Analytics and Data Science
2. Data Types
3. Descriptive Analytics
4. Predictive Analytics (Machine Learning and AI)
5. Data Analytics Platform Design
6. Workshop: Data Analytics Use Case

หัวข้อในการฝึกอบรม

Introduction to Data Analytics and Data Science

1. Introduction to Data Analytics and Data Science

ความสำคัญของข้อมูลในองค์กรยุคดิจิทัล

- ข้อมูล = ทรัพยากรที่มีค่าที่สุดขององค์กร
- ช่วยให้เข้าใจภาคอุตสาหกรรม แนวโน้มการผลิต และประสิทธิภาพการดำเนินงาน
- **ประโยชน์หลัก:**
  - วางแผนนโยบายมาตรฐานและอุตสาหกรรม
  - เพิ่มประสิทธิภาพการตรวจสอบและรับรอง
  - ลดต้นทุนและความเสี่ยงด้านคุณภาพ
  - สร้างความโปร่งใสและธรรมาภิบาล

สถิติ: องค์กรที่ใช้ Data-Driven Decision Making มี productivity สูงขึ้น 5–6%

DIKW Pyramid — ลำดับชั้นของข้อมูล

- **Data:** ข้อเท็จจริงดิบ เช่น ตัวเลขผลผลิตอ้อยแต่ละแปลง
- **Information:** ข้อมูลที่ผ่านการจัดระเบียบ เช่น ผลผลิตรวมรายจังหวัด
- **Knowledge:** การตีความ เช่น จังหวัดที่มีผลผลิตสูงมักมี มอก.
- **Wisdom:** การนำไปใช้ตัดสินใจ เช่น กำหนดนโยบายส่งเสริม มอก.

Data Analytics vs Data Science

Data Analytics	Data Science
วิเคราะห์ข้อมูลในอดีต	ครอบคลุมอดีต ปัจจุบัน และอนาคต
สถิติ + Visualization	ML + AI ขั้นสูง
"เกิดอะไรขึ้น" / "ทำไม"	"จะเกิดอะไรขึ้น" / "ควรทำอย่างไร"
Tools: Excel, SQL, BI	Tools: Python, R, ML Frameworks

Data Science = Data Analytics + Machine Learning + Domain Knowledge

4 ระดับของการวิเคราะห์ข้อมูล

ระดับ	คำถามหลัก	วิธีการ	มูลค่า
Descriptive	เกิดอะไรขึ้น?	สถิติ, Visualization, Dashboard	✅
Diagnostic	ทำไมจึงเกิด?	Drill-down, Correlation, Root Cause	✅✅
Predictive	จะเกิดอะไรขึ้น?	Regression, Classification, ML	✅✅✅
Prescriptive	ควรทำอย่างไร?	Optimization, Simulation, Decision Trees	✅✅✅✅

CRISP-DM Framework

1. **Business Understanding** — ทำความเข้าใจธุรกิจ/นโยบาย
2. **Data Understanding** — รวบรวมและสำรวจข้อมูล
3. **Data Preparation** — เตรียมและทำความสะอาดข้อมูล
4. **Modeling** — สร้างโมเดล
5. **Evaluation** — ประเมินผล
6. **Deployment** — นำไปใช้งาน

หมายเหตุ: CRISP-DM เป็น iterative — สามารถย้อนกลับไปขั้นก่อนหน้าได้

บทบาทของข้อมูลในการสนับสนุนการตัดสินใจ

Data-Driven Decision Making

- **เชิงนโยบาย** — กำหนดมาตรฐานอุตสาหกรรม, วางแผนการผลิตอ้อย
- **เชิงปฏิบัติการ** — จัดสรรทรัพยากรตรวจสอบ, บริหารปริมาณอ้อยเข้าหีบ
- **เชิงยุทธศาสตร์** — กำหนดเขตอุตสาหกรรม, วางแผนส่งออกน้ำตาล

แนวทาง	ลักษณะ	ความเสี่ยง
Intuition-based	ใช้ประสบการณ์ล้วน	สูง
Data-informed	ข้อมูลประกอบการตัดสินใจ	ปานกลาง
Data-driven	ข้อมูลนำการตัดสินใจ	ต่ำที่สุด

ตัวอย่างการประยุกต์ใช้

หน่วยงาน	การประยุกต์ใช้
สมอ.	วิเคราะห์แนวโน้มการขอ มอก., พยากรณ์ความเสี่ยงสินค้าไม่ได้มาตรฐาน
สมอ.	Data Dashboard สถานะการตรวจรับรองโรงงาน
สำนักงานอ้อย	พยากรณ์ผลผลิตอ้อยรายฤดู, วิเคราะห์ราคาน้ำตาล
สำนักงานอ้อย	วางแผนการจัดสรรปริมาณอ้อยให้โรงงาน

2. Data Types

ประเภทของข้อมูล

Structured — ฐานข้อมูลทะเบียนโรงงาน, ผลตรวจ มอก., ปริมาณอ้อย yield

Semi-Structured — JSON จาก API กรมศุลกากร, XML รายงานห้องปฏิบัติการ

Unstructured — รูปภาพการตรวจสอบ, รายงานผู้ตรวจประเมิน, เอกสารมาตรฐาน

สัดส่วนในองค์กร: Structured 20% · Semi-Structured 10% · Unstructured 70%

ตัวอย่าง JSON — ข้อมูลการตรวจ มอก.

```
{
  "cert_no": "มอก.123-2565",
  "manufacturer": "บริษัท ABC จำกัด",
  "status": "ผ่าน",
  "test_date": "2025-06-01",
  "test_results": [
    {"parameter": "ความแข็งแรง", "result": "ผ่าน"},
    {"parameter": "ขนาด", "result": "ผ่าน"}
  ]
}
```

แหล่งที่มาของข้อมูล

ภายในองค์กร	ภายนอกองค์กร
ฐานข้อมูลทะเบียนผู้ประกอบการ	API กรมศุลกากร
ระบบตรวจสอบและรับรอง	ข้อมูลอุตสาหกรรมรายจังหวัด
ระบบสารบรรณและเอกสาร	Open Data กระทรวงเกษตร
ข้อมูลประวัติการตรวจประเมิน	การสำรวจพื้นที่เพาะปลูก

ตัวอย่าง — โหลดข้อมูลด้วย Python

```
import pandas as pd
import requests

# Internal: ทะเบียนผู้ประกอบการ
factory = pd.read_csv("factory_registration.csv")

# External API: กรมศุลกากร (สมมติ)
resp = requests.get("https://api.customs.go.th/trade/sugar")
trade_data = resp.json()

# External: ข้อมูลเกษตร
agri = pd.read_excel("cane_production_2025.xlsx")
```

Open in Colab

คุณภาพข้อมูล (Data Quality Dimensions)

มิติ	คำอธิบาย	ตัวอย่างใน สมอ./อ้อย
Accuracy	ข้อมูลถูกต้องตรงความจริง	ทะเบียนโรงงานตรงกับสถานที่จริง
Completeness	ข้อมูลครบถ้วนสมบูรณ์	ไม่มี missing ค่า CCS ของอ้อย
Consistency	ข้อมูลสอดคล้องกัน	รหัสจังหวัดตรงกันทั้ง 2 หน่วยงาน
Timeliness	ข้อมูลทันสมัย	ข้อมูล มอก. อัปเดตภายใน 24 ชม.
Validity	ข้อมูลอยู่ในรูปแบบที่ถูกต้อง	เลข มอก. ตรงตาม format ที่กำหนด
Uniqueness	ไม่มี duplicate	โรงงาน 1 แห่งมีทะเบียนเดียว

Data Preprocessing — ขั้นตอนเตรียมข้อมูล

1. **Data Cleaning** — จัดการ missing values, outliers, duplicates
2. **Data Integration** — รวมข้อมูลจากหลายแหล่ง
3. **Data Transformation** — Normalize, Encode, Feature Engineering
4. **Data Reduction** — เลือก feature ที่สำคัญ, dimensionality reduction
5. **Data Discretization** — แปลงข้อมูลต่อเนื่องเป็นกลุ่ม

แนวทางการจัดเก็บและบริหารจัดการข้อมูล

Data Governance:

- **Data Quality** — ความถูกต้อง สมบูรณ์ สอดคล้อง
- **Data Security** — ควบคุมการเข้าถึง เข้ารหัสข้อมูล
- **Data Privacy** — ปฏิบัติตาม PDPA
- **Lifecycle Management** —> สร้าง -> เก็บ -> ใช้ -> ทำลาย

เทคโนโลยี: Data Warehouse · Data Lake · Data Lakehouse

ตัวอย่าง — Data Quality Check

```
df = pd.read_csv("certification_data.csv")

print(" Missing values:\n", df.isnull().sum())
print(" Duplicates:", df.duplicated().sum())
print(" Shape:", df.shape)
print(" Data types:\n", df.dtypes)

# ตรวจสอบวันที่
df["cert_date"] = pd.to_datetime(df["cert_date"])
print(" Date range:", df["cert_date"].min(), "–", df["cert_date"].max())
```

กรณีศึกษา: การตรวจสอบมาตรฐาน มอก.

โจทย์: โรงงานที่ได้รับ มอก. แล้วมีอัตราการทวนซ้ำเพื่อขอต่ออายุเพิ่มขึ้น

ข้อมูลที่ใช้	ประเภท
ทะเบียน มอก. และวันหมดอายุ	Structured
รายงานผลตรวจห้องปฏิบัติการ	Semi-Structured
ภาพถ่ายกระบวนการผลิต	Unstructured

ผลลัพธ์: พบว่าโรงงาน SMEs ขาดความรู้ในการรักษาระบบคุณภาพ

แนวทางแก้ไข: จัดอบรมให้ความรู้ก่อนวันหมดอายุ 3 เดือน + ระบบเตือนอัตโนมัติ

3. Descriptive Analytics

หลักการวิเคราะห์เชิงพรรณนา

ตอบคำถาม: "เกิดอะไรขึ้น?" (What happened?)

ขั้นตอน:

1. รวบรวมข้อมูลจากแหล่งต่าง ๆ
2. ทำความสะอาดข้อมูล (Data Cleaning)
3. สรุปข้อมูลด้วยสถิติพื้นฐาน
4. สร้าง Visualization
5. ตีความและสรุปผล

เครื่องมือทางสถิติที่ใช้ใน Descriptive Analytics

กลุ่ม	ตัวอย่าง
Central Tendency	Mean, Median, Mode
Dispersion	Range, Variance, Std Dev, IQR
Distribution	Frequency, Histogram, Skewness
Relationship	Correlation, Cross-tabulation

ประเภทของตัวแปร (Variable Types)

ประเภท	คำอธิบาย	ตัวอย่าง
Numerical (ตัวเลข)		
— Continuous	ค่าต่อเนื่อง	ปริมาณอ้อย (กก.), ราคาน้ำตาล (บาท)
— Discrete	ค่าไม่ต่อเนื่อง	จำนวนโรงงาน, จำนวน มอก.
Categorical (หมวดหมู่)		
— Nominal	ไม่มีลำดับ	จังหวัด, ประเภทอุตสาหกรรม
— Ordinal	มีลำดับ	ระดับคุณภาพ (ดี/ปานกลาง/ต้องปรับปรุง)

ข้อควรจำ: ชนิดของตัวแปรกำหนดวิธีการวิเคราะห์ที่เหมาะสม

การแจกแจงความถี่ (Frequency Distribution)

ความถี่สัมบูรณ์ (Absolute Frequency): จำนวนครั้งที่ค่าปรากฏ

ความถี่สัมพัทธ์ (Relative Frequency): สัดส่วนเมื่อเทียบกับทั้งหมด

ความถี่สะสม (Cumulative Frequency): ผลรวมความถี่สะสมจากน้อยไปมาก

ตัวอย่าง — การแจกแจงผลผลิตอ้อย:

ช่วงผลผลิต (กก./ไร่)	ความถี่ (จำนวนแปลง)	ร้อยละ	สะสม
< 8,000	25	12.5%	12.5%
8,000–10,000	68	34.0%	46.5%
10,000–12,000	72	36.0%	82.5%
> 12,000	35	17.5%	100%

การวัดแนวโน้มเข้าสู่ส่วนกลาง

Mean (ค่าเฉลี่ย) — ผลรวม / จำนวน

- ข้อดี: ใช้ข้อมูลทุกค่า
- ข้อเสีย: อ่อนไหวต่อ outlier

Median (มัธยฐาน) — ค่ากึ่งกลาง

- ข้อดี: ไม่ได้รับผลจาก outlier
- ใช้เมื่อข้อมูลเบ้ (skewed)

การวัดแนวโน้มเข้าสู่ส่วนกลาง (ต่อ)

Mode (ฐานนิยม) — ค่าที่ปรากฏบ่อยที่สุด

- ใช้กับข้อมูล categorical ได้

ตัวอย่าง: วิเคราะห์ปริมาณอ้อยเฉลี่ยต่อไร่ของเกษตรกร

ตัวอย่าง — Central Tendency ใน Python

```
import pandas as pd

df = pd.read_csv("cane_production.csv")

mean_yield = df["yield_per_rai"].mean()
median_rai = df["yield_per_rai"].median()
mode_rai = df["yield_per_rai"].mode()[0]

print(f"Mean yield:   {mean_yield:.2f} กิโลกรัม/ไร่")
print(f"Median yield: {median_rai:.2f} กิโลกรัม/ไร่")
print(f"Mode yield:   {mode_rai:.2f} กิโลกรัม/ไร่")

# Mean vs Median บอกอะไร?
if mean_yield > median_rai:
    print("มีเกษตรกรบางรายได้ผลผลิตสูงมาก (เบ้ขวา)")
elif mean_yield < median_rai:
    print("เกษตรกรส่วนใหญ่ได้ผลผลิตต่ำ (เบ้ซ้าย)")
else:
    print("กระจายตัวสมมาตร")
```

การวัดการกระจายของข้อมูล

Range (พิสัย) — สูงสุด - ต่ำสุด

- ง่ายแต่ไม่ทนต่อ outlier

Variance (ความแปรปรวน) — ค่าเฉลี่ยของ (ส่วนเบี่ยงเบน)^2

- $\sigma^2 = \Sigma(x_i - \mu)^2 / N$

การวัดการกระจายของข้อมูล (ต่อ)

Standard Deviation (ส่วนเบี่ยงเบนมาตรฐาน) — √Variance

- หน่วยเดียวกับข้อมูลเดิม
- 68-95-99.7 Rule: $\mu \pm 1\sigma = 68\%$, $\mu \pm 2\sigma = 95\%$, $\mu \pm 3\sigma = 99.7\%$

IQR — Q3 - Q1

- ใช้หาค่า outlier: Q1 - 1.5×IQR หรือ Q3 + 1.5×IQR

การแจกแจงของข้อมูล (Distribution)

Normal Distribution (การแจกแจงปกติ)

- ข้อมูลสมมาตร Mean = Median = Mode
- เช่น น้ำหนักบรรจุของสินค้าที่ได้มาตรฐาน

Skewed Distribution (การแจกแจงเบ้)

- **เบ้ขวา** Mean > Median (ค่าสูงผิดปกติบางค่า)
- **เบ้ซ้าย** Mean < Median (ค่าต่ำผิดปกติบางค่า)
- เช่น การกระจายของรายได้เกษตรกร

ตัวอย่าง — Dispersion ใน Python

```
# วิเคราะห์การกระจายของราคาน้ำตาล
prices = df["sugar_price"]

print(f"Std Dev: {prices.std():,.2f}")
print(f"Variance: {prices.var():,.2f}")
Q1 = prices.quantile(0.25)
Q3 = prices.quantile(0.75)
iqr = Q3 - Q1
print(f"IQR: {iqr:,.2f}")

# ตรวจจับราคาที่ผิดปกติ (Outlier)
lower = Q1 - 1.5 * iqr
upper = Q3 + 1.5 * iqr
outliers = df[(prices < lower) | (prices > upper)]
print(f"Outlier found: {len(outliers)} เดือน")
```

สถิติพื้นฐานเพื่อการวิเคราะห์

เครื่องมือ	การใช้งาน
Correlation Analysis	ผลิตอ้อยสัมพันธ์กับปริมาณน้ำฝนหรือไม่?
Cross-Tabulation	จำนวน มอก. แยกตามประเภทอุตสาหกรรม
Trend Analysis	แนวโน้มการส่งออกน้ำตาล 5 ปี

ตัวอย่าง: ความสัมพันธ์ระหว่างปริมาณน้ำฝนกับผลผลิตอ้อย:

```
corr = df["rainfall_mm"].corr(df["yield_per_rai"])
print(f"r = {corr:.3f}")
# r > 0  ฝนมาก ผลผลิตมากขึ้น
# r < 0  ฝนมาก ผลผลิตลดลง (น้ำท่วม)
# r ≈ 0  ไม่สัมพันธ์กัน
```

หลักการของ Correlation

ค่า r	ความสัมพันธ์
0.9 – 1.0	สูงมาก (positive)
0.7 – 0.9	สูง
0.5 – 0.7	ปานกลาง
0.3 – 0.5	ต่ำ
0.0 – 0.3	น้อยมาก

ข้อควรระวัง: Correlation ≠ Causation

(ความสัมพันธ์ไม่ใช่สาเหตุ)

การนำเสนอผลการวิเคราะห์

แผนภูมิที่พบบ่อย:

แผนภูมิ	การใช้งาน
Bar Chart	เปรียบเทียบจำนวน มอก. แยกตามประเภท
Line Chart	แนวโน้มราคาน้ำตาลรายเดือน
Pie Chart	สัดส่วนพื้นที่ปลูกอ้อยรายภาค
Histogram	การกระจายของผลผลิตต่อไร่
Box Plot	แสดงค่ากลางและการกระจาย + outlier
Scatter Plot	ความสัมพันธ์ระหว่าง 2 ตัวแปร

หลักการเลือก Visualization: รู้จักข้อมูล → รู้จักผู้ชม → เลือกให้เหมาะสม

ตัวอย่าง — Python Visualization

```
import matplotlib.pyplot as plt

# Bar Chart: มอก. แยกตามประเภท
df.groupby("industry_type")["cert_count"].sum() \
  .plot(kind="bar")
plt.title("จำนวน มอก. แยกตามประเภทอุตสาหกรรม")
plt.tight_layout()
plt.show()

# Line Chart: ราคาน้ำตาล
df.groupby("month")["sugar_price"].mean() \
  .plot(kind="line", marker="o")
plt.title("แนวโน้มราคาน้ำตาลรายเดือน")
plt.grid(True)
plt.show()
```

4. Predictive Analytics

(Machine Learning and AI)

แนวคิด AI และ Machine Learning

AI — ความสามารถของเครื่องจักรในการแสดงพฤติกรรมชาญฉลาด

Machine Learning — แขนงหนึ่งของ AI ที่สอนให้คอมพิวเตอร์เรียนรู้จากข้อมูล

Deep Learning — แขนงของ ML ที่ใช้ Neural Network หลายชั้น

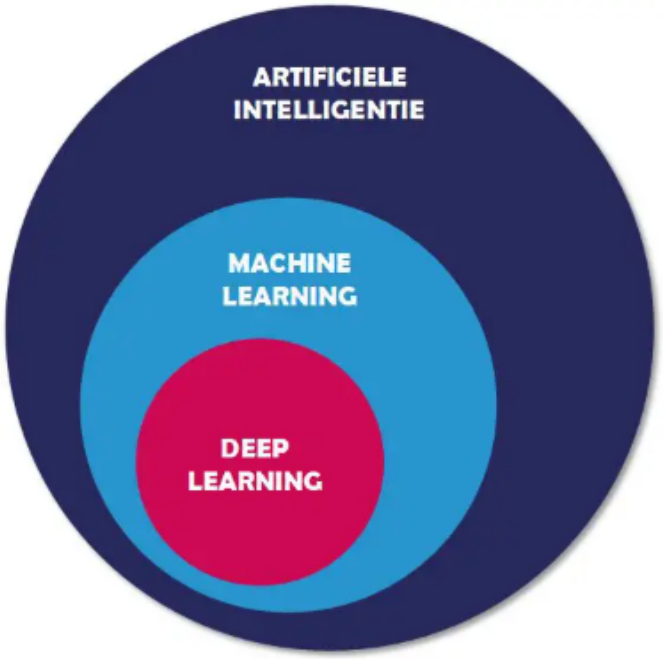

The relationship between AI, ML and DL shown schematically.

ประเภทของ Machine Learning

ประเภท	คำอธิบาย	อัลกอริทึม
Supervised	เรียนรู้จาก Labeled Data	Linear Regression, Decision Tree, Random Forest
Unsupervised	เรียนรู้จาก Unlabeled Data	K-Means, PCA, Hierarchical Clustering
Semi-Supervised	ผสมทั้ง labeled และ unlabeled	Self-training, SSL
Reinforcement	เรียนรู้จาก Reward/Penalty	Q-Learning, DQN, PPO

ความแตกต่างสำคัญ: Supervised ต้องการข้อมูลที่มีคำตอบ, Unsupervised ไม่ต้องการ

Supervised Learning: Regression vs Classification

มิติ	Regression	Classification
Output	ค่าตัวเลขต่อเนื่อง	หมวดหมู่/คลาส
ตัวอย่าง	พยากรณ์ yield อ้อย	จำแนกผ่าน/ไม่ผ่าน มอก.
Evaluation	MSE, MAE, R^2	Accuracy, Precision, Recall
Example Algo	Linear Regression, Random Forest Regressor	Logistic Regression, Decision Tree Classifier

ข้อควรจำ: ต้องเลือก algorithm ให้เหมาะกับประเภทของ output

Traditional vs Predictive Analytics

Traditional	Predictive
วิเคราะห์อดีต	พยากรณ์อนาคต
สถิติพื้นฐาน	ML & AI
"เกิดอะไรขึ้น"	"จะเกิดอะไรขึ้น"
รายงานผล	วางแผนล่วงหน้า
ใช้ข้อมูลทั้งหมด	ต้องแบ่ง Train/Test

Train/Test Split — ความสำคัญ

ทำไมต้องแบ่งข้อมูล?

- เพื่อประเมินว่าโมเดล generalize ได้ดีแค่ไหน
- ป้องกัน **Overfitting** (จำแต่ข้อมูล train)

แนวคิด: ไม่ควรใช้ข้อมูลชุดเดียวทั้งสอนและสอบ

- เหมือนนักเรียนที่สอบข้อสอบเดียวกับที่ท่องจำ

สัดส่วนการแบ่งข้อมูลที่นิยม

ชุดข้อมูล	สัดส่วน	ใช้สำหรับ
Training	70-80%	ฝึกโมเดล
Testing	20-30%	ทดสอบประสิทธิภาพ
Validation	(optional)	ปรับ hyperparameters

Overfitting vs Underfitting

สถานะ	อาการ	สาเหตุ	วิธีแก้
Underfitting	โมเดลไม่ดีทั้ง train และ test	โมเดลง่ายเกินไป, feature ไม่พอ	เพิ่ม complexity, เพิ่ม features
Overfitting	train ดีมาก แต่ test แย่	โมเดลซับซ้อนเกินไป, ข้อมูลน้อย	Regularization, ลด features, เพิ่มข้อมูล

Bias-Variance Tradeoff

สถานะ	Bias	Variance	ผลลัพธ์
Underfitting	สูง	ต่ำ	เรียนรู้ไม่พอ
Overfitting	ต่ำ	สูง	จดจำเกินไป

เป้าหมาย: หาจุดสมดุลระหว่าง Bias และ Variance

ตัวอย่าง — พยากรณ์ผลผลิตอ้อย

```
from sklearn.linear_model import LinearRegression

X = df[["rainfall_mm", "fertilizer_kg",
        "area_rai"]]  # features
y = df["yield_per_rai"]               # target

model = LinearRegression()
model.fit(X, y)

# พยากรณ์
pred = model.predict([[1200, 50, 10]])
print(f"พยากรณ์ผลผลิต: {pred[0]:.2f} กก./ไร่")

# สัมประสิทธิ์
for col, coef in zip(X.columns, model.coef_):
    print(f"{col}: {coef:.2f}")
```

ตัวอย่าง — จำแนกความเสี่ยงสินค้าไม่ได้มาตรฐาน

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import train_test_split

X = df[["factory_size", "years_certified",
        "num_audit_findings", "product_type"]]
y = df["non_compliant"]  # 1 = ไม่ผ่าน, 0 = ผ่าน

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)

model = RandomForestClassifier(n_estimators=100)
model.fit(X_train, y_train)

accuracy = model.score(X_test, y_test)
print(f"Accuracy: {accuracy:.2%}")
```

การประเมินโมเดล Classification

Confusion Matrix:

	พยากรณ์ Positive	พยากรณ์ Negative
จริง Positive	✅ TP (True Positive)	❌ FN (False Negative)
จริง Negative	❌ FP (False Positive)	✅ TN (True Negative)

Metrics สำหรับ Classification

Metric	สูตร	เหมาะกับ
Accuracy	(TP+TN) / Total	ข้อมูลสมดุล
Precision	TP / (TP+FP)	ต้องการความเชื่อมั่นสูง
Recall	TP / (TP+FN)	ต้องการจับให้ครบ
F1-Score	2×P×R / (P+R)	ข้อมูลไม่สมดุล
AUC-ROC	Area under curve	ความสามารถแยกคลาส

การประยุกต์ใช้กับ สมอ. และ สำนักงานอ้อย

Use Case 1: สมอ. — พยากรณ์แนวโน้มการขอ มอก.

```
features = ["gdp_growth", "new_factory_count",
            "import_tariff", "industry_index"]
X = df[features]
y = df["application_count"]

model = RandomForestRegressor(n_estimators=100)
model.fit(X, y)

for feat, imp in zip(features, model.feature_importances_):
    print(f"{feat}: {imp:.2%}")
```

การประยุกต์ใช้กับ สมอ. และ สำนักงานอ้อย

Use Case 2: สำนักงานอ้อย — จัดกลุ่มเกษตรกรตามศักยภาพ

```
from sklearn.cluster import KMeans

X = df[["area_rai", "yield_per_rai", "cost_per_rai",
        "ccs_percentage"]]

kmeans = KMeans(n_clusters=3, random_state=42)
df["farmer_group"] = kmeans.fit_predict(X)

print(df.groupby("farmer_group").agg({
    "area_rai": "mean", "yield_per_rai": "mean"
}))

# Group 0 = ศักยภาพสูง
# Group 1 = ศักยภาพปานกลาง
# Group 2 = ต้องการพัฒนา
```

การประเมินโมเดล Unsupervised (Clustering) (1/2)

Inertia (Within-cluster sum of squares)

- ผลรวมระยะทาง squared ภายใน cluster
- ยิ่งน้อยยิ่งดี

Silhouette Score

- วัดว่าแต่ละจุดอยู่ถูก cluster หรือไม่
- ค่าอยู่ระหว่าง -1 ถึง 1
- 0.5 = จัดกลุ่มได้ดี

การประเมินโมเดล Unsupervised (Clustering) (2/2)

Elbow Method — หาจำนวน cluster ที่เหมาะสม:

```
inertias = []
for k in range(1, 11):
    km = KMeans(n_clusters=k)
    km.fit(X)
    inertias.append(km.inertia_)
# plot inertias → เลือก k ที่กราฟเริ่มหัก
```

ข้อควรระวังในการใช้ Predictive Models

⚠️ **โมเดลพยากรณ์ไม่แม่นยำ 100%**

- ต้องติดตามและปรับปรุงโมเดลอย่างสม่ำเสมอ
- **Ethical AI:** ระวัง Bias ในข้อมูล
- ข้อมูลที่มีคุณภาพ → ผลลัพธ์ที่มีคุณภาพ
- ใช้เป็นเครื่องมือช่วยตัดสินใจ ไม่ใช่คำตัดสิน
- **Garbage In, Garbage Out (GIGO):** โมเดลดีแค่ไหนก็ไม่ช่วยถ้าข้อมูลไม่ดี

5. Data Analytics Platform Design

สถาปัตยกรรมระบบวิเคราะห์ข้อมูล 4 ชั้น

1. **Data Source** — ทะเบียนโรงงาน, ผลตรวจ, ศุลกากร, เกษตร
2. **Data Ingestion** — ETL รายวัน, API เชื่อมต่อหน่วยงาน
3. **Data Storage** — Data Warehouse รวมข้อมูล มอก. + อ้อย
4. **Analysis & Viz** — Power BI Dashboard, Python Analytics

รูปแบบ Data Processing: Batch vs Real-time

มิติ	Batch Processing	Real-time / Streaming
ความถี่	รายวัน/รายชั่วโมง	ทันทีเมื่อมีข้อมูล
ปริมาณข้อมูล	มาก	ปานกลาง
ความหน่วง	นาที–ชั่วโมง	วินาที–นาที
ต้นทุน	ต่ำกว่า	สูงกว่า
ใช้กับ	รายงานสรุป, Data Warehouse	Alert, Dashboard real-time

ตัวอย่าง Batch: สรุปยอด มอก. รายเดือน

ตัวอย่าง Real-time: แจ้งเตือนเมื่อตรวจพบสินค้าไม่ได้มาตรฐาน

Data Modeling Concepts: Star Schema

Fact Table (ตารางข้อเท็จจริง):

- เก็บข้อมูลเชิงปริมาณที่ต้องการวิเคราะห์
- เช่น ยอด มอก., ปริมาณอ้อย, ราคา

Dimension Tables (ตารางมิติ):

- เก็บข้อมูลที่เป็นมิติสำหรับการวิเคราะห์
- เช่น ตารางเวลา, จังหวัด, ประเภทอุตสาหกรรม

ข้อดี: Query เร็ว, เข้าใจง่าย, เหมาะกับ Data Warehouse

Data Pipeline — ตัวอย่าง ETL

```
# Extract: ดึงข้อมูลจากหลายแหล่ง
factory = pd.read_sql("SELECT * FROM factories", conn_db)
trade = pd.read_csv("sugar_export_2025.csv")
weather = pd.read_json("rainfall_data.json")

# Transform: รวมและทำความสะอาด
merged = factory.merge(trade, on="province", how="left")
merged["year"] = pd.to_datetime(merged["date"]).dt.year
merged = merged.dropna(subset=["factory_id"])

# Load: บันทึกลง Data Warehouse
merged.to_sql("agg_factory_trade", conn_dw,
              if_exists="append", index=False)
```

แนวทางการออกแบบแพลตฟอร์ม

1. **Scalability** — รองรับข้อมูลที่เพิ่มขึ้นทุกปี
2. **Reliability** — Backup & Recovery, SLA > 99.5%
3. **Security** — RBAC, Encryption, PDPA
4. **Cost Efficiency** — Cloud Infrastructure
5. **Maintainability** — Modular design, มี Documentation

เทคโนโลยีที่นิยมในแต่ละชั้น

ชั้น	เทคโนโลยี
Storage	PostgreSQL, BigQuery, S3, Data Lake
Processing	Apache Spark, dbt, Airflow
BI	Power BI, Tableau, Metabase
ML	Python, MLflow, SageMaker

ตัวอย่าง — Data Quality Validation

```
def validate_factory_data(df):
    checks = {
        "valid_tis_no": df["tis_no"].str.match(
            r"^มอก\.\d+-\d{4}$"
        ).all(),
        "future_dates": (
            df["cert_date"] <= pd.Timestamp.now()
        ).all(),
        "non_null": df[["factory_name",
                        "province"]].notnull().all().all()
    }
    for name, passed in checks.items():
        print(f"  [{'PASS' if passed else 'FAIL'}] {name}")
```

การเชื่อมโยงข้อมูลจากหลายแหล่ง

ความท้าทาย:

- รูปแบบข้อมูลต่างกัน (สมอ. = มาตรฐาน, อ้อย = เกษตร)
- คุณภาพข้อมูลไม่เท่ากัน
- ความถี่อัปเดตต่างกัน
- ข้อจำกัดด้านความปลอดภัย

แนวทางแก้ไข:

- Data Integration Tools (NiFi, Talend)
- API Gateway
- Data Virtualization
- Master Data Management (MDM)

ตัวอย่าง — Merge ข้อมูลระหว่างหน่วยงาน

```
# สมอ.: ทะเบียนผู้ประกอบการ
tis = pd.read_sql("SELECT * FROM tis_cert", conn_tis)

# อ้อย: ปริมาณการผลิต
cane = pd.read_csv("cane_production.csv")

# Merge ด้วย province + year
analysis = tis.merge(cane,
    left_on=["province", "year"],
    right_on=["province", "year"],
    how="inner")

print(f"Merged: {analysis.shape}")
```

6. Workshop: Data Analytics Use Case

การวิเคราะห์โจทย์ทางธุรกิจ

โจทย์ร่วม: วิเคราะห์ความสัมพันธ์ระหว่างการได้รับมาตรฐาน มอก. กับผลผลิตอ้อยในแต่ละจังหวัด

ทำความเข้าใจปัญหา

- โรงงานในพื้นที่ปลูกอ้อยได้รับ มอก. สัดส่วนเท่าไร?
- จังหวัดที่มี มอก. มาก ส่งผลต่อราคาอ้อยหรือไม่?
- แนวทางส่งเสริมคุณภาพในกลุ่มจังหวัดที่ยังไม่ได้รับ มอก.?

แปลงเป็นโจทย์ Data Analytics

- หา Correlation ระหว่างจำนวน มอก. กับผลผลิตอ้อย
- จัดกลุ่มจังหวัดตามศักยภาพ
- สร้าง Dashboard เฝ้าระวัง

การออกแบบแนวทางวิเคราะห์

1. **Define Objective** — วิเคราะห์ความเชื่อมโยง มอก. กับอุตสาหกรรมอ้อย
2. **Data Collection** — ข้อมูล มอก.จาก สมอ. + ข้อมูลอ้อยจาก สำนักงานอ้อย
3. **Data Preparation** — รวมข้อมูลระดับจังหวัด, clean missing values
4. **Analysis Method** — Correlation + Clustering + Visualization
5. **Validation** — ตรวจสอบความถูกต้องของข้อมูลด้วยเจ้าหน้าที่
6. **Deployment** — สร้าง Dashboard ร่วมกัน 2 หน่วยงาน

เป้าหมายเชิงนโยบาย: นำผลวิเคราะห์ไปใช้กำหนดแนวทางส่งเสริม มอก. ในจังหวัดที่เป็นแหล่งปลูกอ้อย

Workshop Code — Data Preparation

```
import pandas as pd
from sklearn.preprocessing import StandardScaler

# ข้อมูลจาก สมอ.
tis = pd.read_csv("tis_by_province.csv")
# ข้อมูลจาก สำนักงานอ้อย
cane = pd.read_csv("cane_production_by_province.csv")

# รวมข้อมูล
df = tis.merge(cane, on=["province", "year"], how="inner")

# สร้าง Features
df["tis_per_factory"] = df["tis_count"] / df["factory_count"]
df["yield_per_rai"] = df["total_production"] / df["total_area"]
df["tis_coverage_pct"] = df["tis_count"] / df["tis_count"].max() * 100
```

Workshop Code — Correlation Analysis

```
import matplotlib.pyplot as plt
import seaborn as sns

# เลือกคอลัมน์ที่เกี่ยวข้อง
cols = ["tis_count", "factory_count",
        "yield_per_rai", "sugar_price",
        "tis_coverage_pct"]
corr_matrix = df[cols].corr()

# Heatmap
plt.figure(figsize=(8, 6))
sns.heatmap(corr_matrix, annot=True,
            cmap="coolwarm", fmt=".2f")
plt.title("Correlation: TIS Standards vs Cane Production")
plt.tight_layout()
plt.show()
```

Workshop Code — Clustering จังหวัด

```
from sklearn.cluster import KMeans

# Features สำหรับจัดกลุ่ม
X = df[["tis_count", "factory_count",
        "yield_per_rai", "total_area"]]

scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# จัดกลุ่ม 4 กลุ่ม
kmeans = KMeans(n_clusters=4, random_state=42)
df["cluster"] = kmeans.fit_predict(X_scaled)

# วิเคราะห์แต่ละกลุ่ม
print(df.groupby("cluster")[
    ["tis_count", "factory_count", "yield_per_rai"]
].mean())

# Group 0 = กลุ่มนำ (มี มอก.สูง ผลผลิตดี)
# Group 3 = กลุ่มพัฒนา (มี มอก.น้อย ต้องการส่งเสริม)
```

Workshop Code — Dashboard Data

```
# สรุปข้อมูลสำหรับ Dashboard
summary = df.groupby("province").agg({
    "tis_count": "sum",
    "factory_count": "sum",
    "total_production": "sum",
    "yield_per_rai": "mean",
    "sugar_price": "mean",
    "cluster": "first"
}).reset_index()

# จังหวัดที่ควรได้รับการส่งเสริม
need_boost = summary[
    summary["cluster"].isin([3, 2])
].sort_values("total_production", ascending=False)

print(f"จังหวัดที่ต้องการส่งเสริม: {len(need_boost)} จังหวัด")
print(need_boost[["province", "tis_count",
                  "factory_count", "yield_per_rai"]])
```

การระบุ KPI (SMART)

- **S**pecific — เฉพาะเจาะจง
- **M**easurable — วัดผลได้
- **A**chievable — บรรลุได้
- **R**elevant — เกี่ยวข้อง
- **T**ime-bound — มีกรอบเวลา

KPI	สูตร	เป้าหมาย
TIS Coverage	จำนวน มอก. / โรงงานทั้งหมด	เพิ่มขึ้น 10%
Cane Yield	ผลผลิต (กก.) / พื้นที่ (ไร่)	> 10,000 กก./ไร่
Correlation	r(tis, yield)	> 0.5
Cluster Improvement	จำนวนจังหวัดกลุ่มพัฒนาลดลง	ลดลง 15%

สรุปประเด็นสำคัญ

1. **Data Analytics / Data Science** คืออะไร, DIKW Pyramid, 4 ระดับการวิเคราะห์
2. **ประเภทของข้อมูล** Structured/Semi/Unstructured, Data Quality, Preprocessing
3. **Descriptive Analytics** สถิติพื้นฐาน, Central Tendency, Dispersion, Distribution
4. **Predictive Analytics & ML** Supervised/Unsupervised, Overfitting, Evaluation Metrics
5. **Data Platform Design** สถาปัตยกรรม 4 ชั้น, ETL, Star Schema
6. **การประยุกต์ใช้ใน สมอ. และ สำนักงานอ้อย**

Code ที่ใช้วันนี้: Python (pandas, scikit-learn, matplotlib, seaborn)

Q & A

THANK YOU

FOR YOUR ATTENTION

สอบถาม/ติดต่อ

คุณจุฬวัฒิ อัญชลีสังกาศ (โอม)

chunlawat@primes.co.th